รายงานโครงงาน

เรื่อง กระบวนการทดลองและดำเนินงานตามหลัก CRISP-DM

จัดทำโดย

นายณัฐวัฒน์	สถานพงศ์	67070052
นายธิติพันธ์	สุนทรปฏิคม	67070079
นายธีระวัฒน์	จึงสวัสดิ์มีชัย	67070083
นางสาวปรภาว์	รักษ์ธนกูล	67070096
นายพิชเญศ	ยันต์โกเศศ	67070116

อาจารย์ประจำวิชา

อาจารย์เฉลิมพล ศิริกายน

รายงานเล่มนี้เป็นส่วนหนึ่งของรายวิชาพื้นฐานวิทยาการข้อมูล

FUNDAMENTALS OF DATA SCIENCE รหัสวิชา 06026208

หลักสูตรวิทยาการข้อมูลและการวิเคราะห์เชิงธุรกิจ

ภาคเรียนที่ 1 ปีการศึกษา 2568

คณะเทคโนโลยีสารสนเทศ สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

คำนำ

รายงานฉบับนี้จัดทำขึ้นเพื่อศึกษาและประยุกต์ใช้กระบวนการวิเคราะห์ข้อมูลตามแนวทาง CRISP-DM (Cross Industry Standard Process for Data Mining) โดยนำข้อมูลค่าฝุ่นละอองขนาดเล็ก PM2.5 ในกรุงเทพมหานครร่วมกับข้อมูลสภาพอากาศมาวิเคราะห์ความสัมพันธ์และสร้างแบบจำลองสำหรับพยากรณ์ค่า PM2.5

การดำเนินงานในโครงงานนี้ครอบคลุมตั้งแต่การทำความเข้าใจปัญหา การรวบรวมข้อมูล การเตรียมข้อมูล การสร้างแบบจำลอง การประเมินผล และการสรุปผลลัพธ์ เพื่อให้เห็นกระบวนการทำงานด้าน Data Science อย่างเป็นระบบ และสามารถนำความรู้ที่ได้ไปประยุกต์ใช้กับงานด้านการวิเคราะห์ข้อมูลในอนาคตได้

ทางคณะผู้จัดทำหวังเป็นอย่างยิ่งว่ารายงานฉบับนี้จะเป็นประโยชน์ต่อผู้ที่สนใจด้านการวิเคราะห์ข้อมูลสิ่งแวดล้อม และสามารถนำแนวทางการทำงานตามกระบวนการ CRISP-DM ไปประยุกต์ใช้กับงานวิเคราะห์ข้อมูลในด้านอื่นต่อไป และหากมีข้อผิดพลาดประการใด คณะผู้จัดทำขออภัยมา ณ ที่นี้

คณะผู้จัดทำ

สารบัญ

หน้า

คำนำ ก

สารบัญ ข

บทที่ 1 บทนำ

1.1 ความเป็นมา 1

1.2 วัตถุประสงค์ 1

1.3 ขอบเขตของโครงงาน 1

บทที่ 2 ข้อมูลที่เกี่ยวข้อง

2.1 ข้อมูล PM2.5 2

2.2 ข้อมูลสถานีตรวจวัด 3

2.3 การเตรียมข้อมูลสำหรับการวิเคราะห์และรวมข้อมูลสภาพอากาศ 4

บทที่ 3 ขั้นตอนการดำเนินงาน

1.1 Business Understanding 5

1.2 Data Understanding 5

1.3 Data Preparation 6

1.4 Modeling 7

1.5 Evaluation 9

1.6 Deployment 9

บทที่ 4 ผลการดำเนินงาน

4.1 ผลการวิเคราะห์ความสัมพันธ์ของข้อมูล 11

4.2 ผลการสร้างแบบจำลองพยากรณ์ 11

บทที่ 5 อภิปรายและสรุปผลการดำเนินงาน

5.1 อภิปรายผลการดำเนินงาน 13

5.2 สรุปผลการดำเนินงาน 13

บทที่ 1

ที่มาและความสำคัญ

1.1 ความเป็นมา

ในปัจจุบัน ปัญหาฝุ่นละอองขนาดเล็กหรือ PM2.5 เป็นหนึ่งในปัญหาสิ่งแวดล้อมที่ส่งผลกระทบต่อคุณภาพชีวิตของประชาชน โดยเฉพาะในเขตเมืองขนาดใหญ่ เช่น Bangkok ซึ่งมีปัจจัยหลายด้านที่เกี่ยวข้องกับการสะสมของฝุ่น เช่น ความหนาแน่นของการจราจร สภาพอากาศ และกิจกรรมในเขตเมือง

ค่าฝุ่น PM2.5 ที่สูงเกินมาตรฐานสามารถส่งผลกระทบต่อสุขภาพ โดยเฉพาะระบบทางเดินหายใจและระบบหัวใจ ทำให้การติดตาม วิเคราะห์ และพยากรณ์แนวโน้มค่าฝุ่นมีความสำคัญมากขึ้น

ในการทำโครงงานนี้ ผู้จัดทำจึงนำข้อมูลค่าฝุ่น PM2.5 รายวันร่วมกับข้อมูลสภาพอากาศมาศึกษา เพื่อวิเคราะห์ความสัมพันธ์ของตัวแปรต่าง ๆ และสร้างแบบจำลองสำหรับพยากรณ์ค่า PM2.5 โดยใช้กระบวนการ CRISP-DM ซึ่งเป็นแนวทางมาตรฐานสำหรับงานวิเคราะห์ข้อมูล

1.2 วัตถุประสงค์

1. เพื่อศึกษาความสัมพันธ์ระหว่างค่า PM2.5 กับข้อมูลสภาพอากาศ
2. เพื่อเตรียมข้อมูลให้อยู่ในรูปแบบที่เหมาะสมสำหรับการวิเคราะห์
3. เพื่อสร้างแบบจำลองสำหรับพยากรณ์ค่า PM2.5 จากข้อมูลที่มี

1.3 ขอบเขตของโครงงาน

1. ใช้ข้อมูลค่า PM2.5 รายวันในพื้นที่ Bangkok ช่วงปี 2021–2024
2. ใช้ข้อมูลสภาพอากาศ ได้แก่ อุณหภูมิ ความชื้นสัมพัทธ์ และความเร็วลม
3. วิเคราะห์ข้อมูลโดยใช้กระบวนการ CRISP-DM
4. ใช้วิธี Regression ในการสร้างแบบจำลองพยากรณ์

บทที่ 2

ข้อมูลที่เกี่ยวข้อง

2.1 ข้อมูล PM2.5

ข้อมูลค่า PM2.5 ที่ใช้ในโครงงานนี้เป็นข้อมูลรายวันในพื้นที่ Bangkok โดยรวบรวมจากไฟล์ข้อมูลแยกตามปี ได้แก่ ปี 2021, 2022, 2023 และ 2024 จากนั้นนำข้อมูลทั้งหมดมารวมเป็นชุดข้อมูลเดียวด้วยคำสั่ง concat ในภาษา Python

หลังจากรวมข้อมูลแล้ว มีการแปลงคอลัมน์วันที่ให้อยู่ในรูปแบบวันที่มาตรฐาน และจัดเรียงข้อมูลตามลำดับเวลาเพื่อให้เหมาะสมต่อการวิเคราะห์

```python
import pandas as pd
import numpy as np
import requests
import matplotlib.pyplot as plt
import seaborn as sns

print("--- 1. โหลดและรวมข้อมูล PM2.5 ---")
# 1. โหลดข้อมูล PM2.5 ทั้ง 4 ปี
df21 = pd.read_csv('pm2.52021.csv')
df22 = pd.read_csv('pm2.52022.csv')
df23 = pd.read_csv('pm2.52023.csv')
df24 = pd.read_csv('pm2.52024.csv')

# 2. รวมไฟล์และจัดการวันที่
df_raw = pd.concat([df21, df22, df23, df24], ignore_index=True)
df_raw['Date'] = pd.to_datetime(df_raw['Date'], format='mixed', dayfirst=True)
df_raw = df_raw.sort_values('Date').reset_index(drop=True)

print("--- 2. ทำความสะอาดข้อมูลสถานี 72T ---")
```

รูปที่ 1 ขั้นตอนการรวมข้อมูลค่า PM2.5 จากหลายปี

2.2 ข้อมูลสถานีตรวจวัด

ภายหลังการรวมข้อมูล มีการตรวจสอบคอลัมน์ข้อมูลของแต่ละสถานีตรวจวัด พบว่าบางสถานีมีข้อมูลแยกเป็นหลายคอลัมน์ เช่น สถานี 72T จึงมีการรวมข้อมูลจากคอลัมน์เดิมและคอลัมน์ใหม่ให้อยู่ในคอลัมน์เดียว เพื่อป้องกันความซ้ำซ้อนของข้อมูล

หลังจากนั้นจึงลบคอลัมน์ที่ไม่จำเป็นออก และเตรียมคอลัมน์สำหรับใช้คำนวณค่าเฉลี่ย

```python
# จัดการคอลัมน์ 72T ก่อนดึงชื่อสถานี (เช็คก่อนว่ามีคอลัมน์นี้ไหม กัน Error ถ้ารันเซลล์ซ้ำ)
if "72T(เก่า)" in df_raw.columns and "72T(ใหม่)" in df_raw.columns:
    df_raw["72T"] = df_raw["72T(เก่า)"].combine_first(df_raw["72T(ใหม่)"])
    df_raw = df_raw.drop(columns=["72T(เก่า)", "72T(ใหม่)"])

print("--- 3. แปลงชนิดข้อมูลและหาค่าเฉลี่ยกทม. ---")
# ดึงชื่อคอลัมน์สถานี *หลังจาก* ลบ 72T เก่า/ใหม่ ไปแล้ว
station_cols = [col for col in df_raw.columns if col != 'Date']

# แปลงค่าทุกคอลัมน์ของสถานีให้เป็นตัวเลข (อะไรที่เป็นตัวอักษรหรือแปลกๆ จะกลายเป็น NaN)
for col in station_cols:
    df_raw[col] = pd.to_numeric(df_raw[col], errors='coerce')

df = pd.DataFrame()
df['Date'] = df_raw['Date']
```

รูปที่ 2 การรวมข้อมูลของสถานีตรวจวัด 72T

2.3 การเตรียมข้อมูลสำหรับการวิเคราะห์และรวมข้อมูลสภาพอากาศ

หลังจากจัดการข้อมูลสถานีตรวจวัดแล้ว จึงทำการเลือกเฉพาะคอลัมน์ของสถานีทั้งหมด เพื่อนำมาคำนวณค่าเฉลี่ย PM2.5 รายวัน โดยใช้ค่าเฉลี่ยจากทุกสถานีในแต่ละวัน และใช้การประมาณค่าช่องว่างด้วยวิธี Linear Interpolation เพื่อให้ข้อมูลมีความต่อเนื่อง

จากนั้นจึงดึงข้อมูลสภาพอากาศรายวันจาก Open-Meteo ในช่วงเวลาเดียวกันกับข้อมูล PM2.5 โดยใช้ข้อมูลพื้นที่กรุงเทพมหานคร และเลือกตัวแปรที่เกี่ยวข้อง ได้แก่

- อุณหภูมิเฉลี่ยรายวัน
- ความชื้นสัมพัทธ์เฉลี่ยรายวัน
- ความเร็วลมสูงสุดรายวัน

เมื่อได้ข้อมูลสภาพอากาศแล้ว จึงนำมารวมเข้ากับข้อมูล PM2.5 ตามคอลัมน์วันที่ (Date) เพื่อสร้างชุดข้อมูลสุดท้ายสำหรับใช้ในการวิเคราะห์และสร้างแบบจำลองในขั้นตอนถัดไป โดยในกรณีที่พบค่าว่างของข้อมูลสภาพอากาศ จะเติมค่าด้วยวิธี Forward Fill เพื่อให้ข้อมูลสมบูรณ์ก่อนนำไปใช้งาน

```python
# หาค่าเฉลี่ยฝุ่นรายวันและจัดการ Missing values (ลบบรรทัดที่ซ้ำออกให้แล้ว)
df['pm25_daily'] = df_raw[station_cols].mean(axis=1).interpolate(method='linear')

print("--- 4. กำลังดึงข้อมูลสภาพอากาศจาก API (Open-Meteo) ---")
url = "https://archive-api.open-meteo.com/v1/archive"
params = {
    "latitude": 13.7563, # ละติจูด กทม.
    "longitude": 100.5018, # ลองจิจูด กทม.
    "start_date": "2021-01-01",
    "end_date": "2024-12-31",
    "daily": ["temperature_2m_mean", "relative_humidity_2m_mean", "wind_speed_10m_max"],
    "timezone": "Asia/Bangkok"
}

response = requests.get(url, params=params)

if response.status_code == 200:
    print("ดึงข้อมูลสำเร็จ! กำลังแปลงและ Merge ข้อมูล...")
    data = response.json()

    df_weather = pd.DataFrame({
        "Date": pd.to_datetime(data["daily"]["time"]),
        "temperature": data["daily"]["temperature_2m_mean"],
        "humidity": data["daily"]["relative_humidity_2m_mean"],
        "wind_speed": data["daily"]["wind_speed_10m_max"]
    })

    # Merge ข้อมูล
    df = pd.merge(df, df_weather, on="Date", how="left")

    # เติมค่าว่างด้วย Forward Fill
    df[['temperature', 'humidity', 'wind_speed']] = df[['temperature', 'humidity', 'wind_speed']].fillna(method='ffill')
    print("Merge ข้อมูลสภาพอากาศเข้ากับตารางหลักเรียบร้อยแล้ว!")
else:
    print(f"เกิดข้อผิดพลาดในการดึงข้อมูล: {response.status_code}")

df = df.dropna().reset_index(drop=True)

print("\n--- แสดงตัวอย่างข้อมูล 5 บรรทัดแรก ---")
display(df.head())

print("\n--- 5. สร้างกราฟ Heatmap ดูความสัมพันธ์ ---")
```

รูปที่ 3 ชุดข้อมูลสุดท้ายหลังจากคำนวณค่าเฉลี่ย PM2.5 รายวันและรวมข้อมูลสภาพอากาศ

บทที่ 3

ขั้นตอนการดำเนินงาน

3.1 Business Understanding

โครงงานนี้จัดทำขึ้นเพื่อศึกษาความสัมพันธ์ระหว่างค่าฝุ่นละอองขนาดเล็กหรือ PM2.5 และข้อมูลสภาพอากาศในพื้นที่เขตกรุงเทพมหานคร แล้วจึงนำข้อมูลดังกล่าวมาสร้างแบบจำลองสำหรับพยากรณ์ค่า PM2.5 รายวันในเบื้องต้น โดยใช้กระบวนการ CRISP-DM เป็นแนวทางหลักในการดำเนินงาน เนื่องจากเป็นกระบวนการที่ช่วยจัดลำดับการทำงานให้เป็นระบบ ตั้งแต่การทำความเข้าใจปัญหา การเตรียมข้อมูล ไปจนถึงการนำผลลัพธ์ไปใช้งาน

ขอบเขตของโครงงานครอบคลุมข้อมูลช่วงปี 2021–2024 และเลือกใช้ตัวแปรด้านสภาพอากาศที่เกี่ยวข้อง ได้แก่ อุณหภูมิ ความชื้นสัมพัทธ์ และความเร็วลม รวมถึงตัวแปรเดือน (month) เพื่อสะท้อนช่วงเวลาของปีที่อาจมีผลต่อระดับฝุ่น PM2.5

สำหรับเกณฑ์ความสำเร็จของโครงงาน คือ (1) ได้ชุดข้อมูลที่ผ่านการเตรียมและสามารถนำไปวิเคราะห์และสร้างโมเดลได้ (2) ได้โมเดลที่สามารถพยากรณ์ค่า PM2.5 ได้ในระดับเหมาะสมสำหรับการใช้งานเบื้องต้น และ (3) สามารถนำโมเดลดังกล่าวไปสร้างระบบสาธิตเพื่อให้ผู้ใช้ทดลองกรอกข้อมูลและดูผลการพยากรณ์ได้อย่างเข้าใจง่าย

3.2 Data Understanding

หลังจากรวบรวมและจัดเตรียมชุดข้อมูลสุดท้ายเรียบร้อยแล้ว ผู้จัดทำได้ทำความเข้าใจข้อมูลในภาพรวม โดยตรวจสอบตัวแปรสำคัญที่ใช้ในโครงงาน ได้แก่ ค่า PM2.5 เฉลี่ยรายวัน อุณหภูมิ ความชื้นสัมพัทธ์ และความเร็วลม เพื่อให้เห็นแนวโน้มเบื้องต้นของข้อมูลก่อนนำไปสร้างแบบจำลอง

ในขั้นตอนนี้มีการวิเคราะห์ความสัมพันธ์ระหว่างตัวแปรด้วยการหาค่าสหสัมพันธ์ (Correlation) และนำเสนอผลในรูปแบบกราฟ Heatmap เพื่อให้เห็นทิศทางและระดับความสัมพันธ์ของตัวแปรแต่ละคู่ได้ชัดเจนยิ่งขึ้น ดังแสดงในรูปที่ 4 ผลการวิเคราะห์ช่วยให้มองเห็นแนวโน้มว่า ตัวแปรสภาพอากาศบางตัวอาจมีความเกี่ยวข้องกับการเปลี่ยนแปลงของค่า PM2.5 และสามารถใช้เป็นข้อมูลประกอบในการคัดเลือกตัวแปรสำหรับสร้างแบบจำลองในขั้นตอนถัดไป

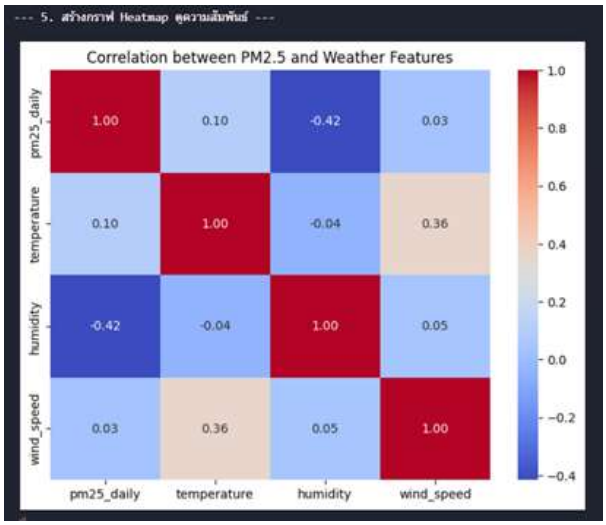

รูปที่ 4 แสดงค่าสหสัมพันธ์ระหว่างค่า PM2.5 กับตัวแปรด้านสภาพอากาศ

3.3 Data Preparation

ก่อนนำข้อมูลเข้าสู่ขั้นตอนการสร้างแบบจำลอง ผู้จัดทำได้เตรียมข้อมูลเพิ่มเติมเพื่อให้เหมาะสมต่อการเรียนรู้ของโมเดล โดยสร้างตัวแปร month จากคอลัมน์วันที่ เพื่อใช้แทนช่วงเวลาของปีซึ่งอาจมีผลต่อระดับฝุ่น PM2.5 จากนั้นกำหนดตัวแปรที่ใช้ในการสร้างแบบจำลอง โดยเลือกตัวแปรอิสระ ได้แก่ month, temperature, humidity และ wind_speed และกำหนดตัวแปรเป้าหมายเป็นค่า pm25_daily จากนั้นเลือกเฉพาะตัวแปรที่ใช้ในการสร้างแบบจำลอง ได้แก่

- month
- temperature
- humidity
- wind_speed
- pm25_daily

นอกจากนี้ได้มีการปรับข้อมูลให้อยู่ในรูปแบบที่เหมาะสมสำหรับการเรียนรู้ของโมเดล เช่น การปรับสเกลข้อมูล (normalize) เพื่อให้ตัวแปรอยู่ในช่วงที่เหมาะสม และการจัดการค่าผิดปกติ (outlier) เพื่อลดผลกระทบของค่าที่เบี่ยงเบนต่อผลการพยากรณ์ โดยตัวอย่างชุดข้อมูลที่ใช้สำหรับสร้างแบบจำลองแสดงดังรูปที่ 5 หลังจากเตรียมข้อมูลเรียบร้อยแล้ว จึงนำชุดข้อมูลนี้ไปใช้ในการสร้างและเปรียบเทียบแบบจำลอง Regression ในขั้นตอนถัดไป

	Date	pm25_daily	temperature	humidity	wind_speed
0	2021-01-01	21.708333	22.2	59	9.7
1	2021-01-02	50.041096	22.6	59	11.4
2	2021-01-03	42.739726	24.2	61	11.5
3	2021-01-04	40.424658	25.4	62	11.7
4	2021-01-05	14.625000	26.4	63	10.8
...	...	...	...	...	...
1272	2024-12-27	28.807447	30.1	54	13.6
1273	2024-12-28	20.921277	28.9	55	14.2
1274	2024-12-29	20.758511	27.4	53	11.1
1275	2024-12-30	27.757895	27.2	56	7.9
1276	2024-12-31	27.910526	27.0	52	10.9

1277 rows × 5 columns

รูปที่ 5 ตารางข้อมูลที่ใช้สำหรับสร้างแบบจำลอง

3.4 Modeling

ในขั้นตอนนี้ผู้จัดทำได้สร้างแบบจำลองเพื่อพยากรณ์ค่า PM2.5 โดยเลือกใช้แนวทางการพยากรณ์แบบ Regression เนื่องจากตัวแปรเป้าหมายเป็นค่าต่อเนื่อง (pm25_daily) และกำหนดตัวแปรอิสระที่ใช้ในการทำนาย ได้แก่ month, temperature, humidity และ wind_speed

เพื่อให้การทดลองเป็นระบบและสามารถเปรียบเทียบแบบจำลองได้อย่างเหมาะสม ผู้จัดทำได้ใช้ไลบรารี PyCaret สำหรับทดลองและเปรียบเทียบโมเดล Regression หลายประเภทภายใต้เงื่อนไขเดียวกัน โดยใช้ค่า RMSE เป็นเกณฑ์หลักในการพิจารณาประสิทธิภาพของโมเดล จากนั้นเลือกโมเดลที่ให้ค่าความคลาดเคลื่อนต่ำที่สุดเพื่อนำไปใช้งานต่อ

```python
# สำคัญ: ต้อง import ให้ครบเพื่อไม่ให้เกิด Error NameError
from pycaret.regression import setup, compare_models, finalize_model
df['month'] = df['Date'].dt.month


# 1. เลือกคอลัมน์ที่จะใช้สอนโมเดล (รวมสภาพอากาศจาก Lab 7)
data_for_model = df[['month', 'temperature', 'humidity', 'wind_speed', 'pm25_daily']]


# 2. Setup PyCaret
reg_setup = setup(
    data=data_for_model,
    target='pm25_daily',
    session_id=42,
    normalize = True, # เพิ่มการ Scaling ข้อมูล
    transformation = True, # ปรับข้อมูลให้เป็น Normal Distribution
    remove_outliers = True, # กำจัดค่าที่เพี้ยนมากๆ ออก
    verbose=False
)

# 3. หาโมเดลที่ดีที่สุด
print("--- กำลังค้นหาโมเดลที่ดีที่สุด ---")
best_model = compare_models(sort='RMSE')

# 4. ล็อคโมเดลเตรียมใช้งานจริง
final_model = finalize_model(best_model)
print("--- สำเร็จ! ได้โมเดลพร้อมนำไป Deployment แล้ว ---")
```

รูปที่ 6 ขั้นตอนการทดลองสร้างแบบจำลองด้วย PyCaret

```
--- กำลังค้นหาโมเดลที่ดีที่สุด ---
```

	Model	MAE	MSE	RMSE	R2	RMSLE	MAPE	TT (Sec)
gbr	Gradient Boosting Regressor	8.0255	128.4591	11.2032	0.2658	0.4183	0.3910	0.2860
rf	Random Forest Regressor	8.0012	131.4455	11.3679	0.2418	0.4296	0.3963	0.4990
knn	K Neighbors Regressor	8.0169	132.3062	11.3755	0.2440	0.4317	0.3862	0.3570
lightgbm	Light Gradient Boosting Machine	8.0727	132.4422	11.3765	0.2442	0.4368	0.3954	0.5830
ridge	Ridge Regression	8.7939	134.8155	11.5117	0.2248	0.4459	0.4470	0.2080
lar	Least Angle Regression	8.7933	134.8167	11.5117	0.2247	0.4460	0.4469	0.2020
lr	Linear Regression	8.7933	134.8167	11.5117	0.2247	0.4460	0.4469	0.8710
br	Bayesian Ridge	8.8056	134.8327	11.5119	0.2249	0.4459	0.4477	0.2060
lasso	Lasso Regression	8.9266	135.2535	11.5303	0.2235	0.4464	0.4564	0.2080
llar	Lasso Least Angle Regression	8.9266	135.2534	11.5303	0.2235	0.4464	0.4564	0.3640
huber	Huber Regressor	8.5945	136.8344	11.5970	0.2133	0.4385	0.4063	0.2080
ada	AdaBoost Regressor	9.2240	136.6340	11.6088	0.2085	0.4728	0.5213	0.2290
en	Elastic Net	9.1440	138.8733	11.6824	0.2040	0.4532	0.4696	0.2070
et	Extra Trees Regressor	8.1675	142.3827	11.8205	0.1820	0.4414	0.4039	0.5700
omp	Orthogonal Matching Pursuit	9.1931	142.9385	11.8672	0.1757	0.4561	0.4662	0.2050
xgboost	Extreme Gradient Boosting	8.6229	153.7421	12.2865	0.1127	0.4625	0.4142	0.2550
par	Passive Aggressive Regressor	9.7812	164.7070	12.7203	0.0442	0.5290	0.4883	0.2020
dummy	Dummy Regressor	10.7526	175.4326	13.1496	-0.0097	0.5152	0.5581	0.2090
dt	Decision Tree Regressor	10.5745	237.2544	15.3756	-0.4160	0.5628	0.5077	0.2130

```
Could not render content for 'application/vnd.jupyter.widget-view+json'
{"version_major":2,"version_minor":0,"model_id":"b78303fd21d54682964cd6fde7e65500"}

--- สำเร็จ! ได้โมเดลพร้อมนำไป Deployment แล้ว ---
```

รูปที่ 7 ตารางเปรียบเทียบโมเดลจาก compare_models()

ผลการเปรียบเทียบโมเดล พบว่า Gradient Boosting Regressor ให้ผลลัพธ์ดีที่สุดตามเกณฑ์ที่กำหนด ดังแสดงในรูปที่ 7 หลังจากนั้นจึงนำโมเดลดังกล่าวเข้าสู่ขั้นตอนการสรุปโมเดลพร้อมใช้งาน (finalize) เพื่อใช้ในการประเมินผลและพัฒนาระบบสาธิตในขั้นตอนถัดไป

3.5 Evaluation

หลังจากเลือกแบบจำลองที่เหมาะสม ผู้จัดทำได้ทำการประเมินประสิทธิภาพของโมเดล โดยพิจารณาค่าความคลาดเคลื่อนจากการพยากรณ์ เพื่อดูว่าโมเดลสามารถทำนายค่า PM2.5 ได้ใกล้เคียงกับค่าจริงมากน้อยเพียงใด โดยใช้ตัวชี้วัดหลักคือ RMSE (Root Mean Squared Error) และพิจารณาค่าประกอบอื่น ๆ เช่น MAE และ R^2 เพื่อช่วยอธิบายผลในภาพรวม

จากผลการประเมินพบว่าโมเดลที่เลือกให้ค่าความคลาดเคลื่อนอยู่ในระดับที่สามารถนำไปใช้งานเบื้องต้นได้ และสะท้อนให้เห็นว่า ตัวแปรด้านสภาพอากาศและช่วงเวลาของปีสามารถช่วยอธิบายแนวโน้มของค่า PM2.5 ได้ในระดับหนึ่ง อย่างไรก็ตาม ผลลัพธ์ยังอาจมีข้อจำกัดจากปัจจัยอื่นที่ไม่ได้อยู่ในชุดข้อมูล เช่น สภาพการจราจร แหล่งกำเนิดมลพิษเฉพาะพื้นที่ หรือเหตุการณ์พิเศษบางช่วงเวลา ซึ่งอาจส่งผลต่อความแม่นยำของการพยากรณ์ได้

ดังนั้นจึงสรุปได้ว่า โมเดลที่ได้เหมาะสำหรับการนำไปสาธิตและใช้งานเบื้องต้น และสามารถนำผลการประเมินไปใช้เป็นแนวทางในการปรับปรุงและพัฒนาโมเดลให้มีความแม่นยำยิ่งขึ้นในอนาคต

3.6 Deployment

หลังจากได้โมเดลสุดท้ายแล้ว ผู้จัดทำจึงได้นำโมเดลนี้ไปพัฒนาเป็นระบบทดลองพยากรณ์ผ่าน Gradio เพื่อให้ผู้ใช้สามารถกรอกข้อมูลที่เกี่ยวข้อง ได้แก่ เดือน (month) อุณหภูมิ ความชื้นสัมพัทธ์ และความเร็วลม จากนั้นระบบจะแสดงค่าพยากรณ์ PM2.5 ที่คาดการณ์ได้ พร้อมทั้งสรุประดับคำแนะนำด้านคุณภาพอากาศในรูปแบบที่เข้าใจง่าย

ระบบสามารถแสดงผลได้ทั้งค่าพยากรณ์และระดับความเสี่ยง เช่น ปลอดภัย ปานกลาง และอันตราย ซึ่งช่วยให้ผู้ใช้งานสามารถเห็นผลลัพธ์จากโมเดลและนำไปประเมินสถานการณ์ได้สะดวกยิ่งขึ้น โดยระบบดังกล่าวเป็นต้นแบบสำหรับการสาธิตการนำโมเดลไปใช้งานในเบื้องต้น

```python
import gradio as gr
import pandas as pd
from pycaret.regression import predict_model # <--- อย่าลืม import ตัวนี้เพิ่ม

def predict_pm25_app(month, temp, hum, wind):
    # จัดรูปข้อมูลให้ตรงกับที่โมเดลเรียนมา (เพิ่ม month เข้ามา)
    input_data = pd.DataFrame({
        'month': [month],
        'temperature': [temp],
        'humidity': [hum],
        'wind_speed': [wind]
    })

    # พยากรณ์ด้วย predict_model ของ PyCaret
    result = predict_model(final_model, data=input_data)

    prediction = result['prediction_label'].iloc[0]

    # เปลี่ยนตัวเลขเป็นคำแนะนำ (Narrative AI)
    if prediction <= 25:
        risk_level = "🟢 คุณภาพอากาศดีมาก (Safe) - ปลอดภัย"
    elif prediction <= 50:
        risk_level = "🟡 ปานกลาง (Moderate) - ระวังสุขภาพ"
    else:
        risk_level = "🔴 อันตราย (Unhealthy) - งดกิจกรรมกลางแจ้ง"

    return f"คาดการณ์ฝุ่น PM2.5: {prediction:.2f} µg/m³\nระดับผลกระทบ: {risk_level}"

app = gr.Interface(
    fn=predict_pm25_app,
    inputs=[
        gr.Slider(1, 12, step=1, label="เดือน (Month)", value=1), # <--- เพิ่ม Slider ให้เลือกเดือน
        gr.Number(label="อุณหภูมิ (°C)", value=32),
        gr.Number(label="ความชื้นสัมพัทธ์ (%)", value=60),
        gr.Number(label="ความเร็วลม (km/h)", value=10)
    ],
    outputs=gr.Textbox(label="ผลการพยากรณ์และคำแนะนำ"),
    title="🌬️ ระบบพยากรณ์ฝุ่น PM2.5 ด้วยข้อมูลสภาพอากาศและฤดูกาล",
    description="ปรับค่าเดือนและสภาพอากาศเพื่อดูแนวโน้มฝุ่น (เดือน 1-4 ฝุ่นจะสูงกว่าปกติ)"
)

app.launch()
```

รูปที่ 8 ตัวอย่างการพัฒนาระบบสาธิตด้วย Gradio

บทที่ 4

ผลการดำเนินงาน

4.1 ผลการวิเคราะห์ความสัมพันธ์ของข้อมูล

จากการวิเคราะห์ความสัมพันธ์ระหว่างค่าฝุ่น PM2.5 กับตัวแปรด้านสภาพอากาศด้วยกราฟ Heatmap พบว่าแต่ละตัวแปรมีความสัมพันธ์กับค่า PM2.5 ในระดับที่แตกต่างกัน โดยความชื้นสัมพัทธ์มีความสัมพันธ์กับค่า PM2.5 ในทิศทางตรงกันข้ามค่อนข้างชัดเจน (ค่าสหสัมพันธ์ประมาณ –0.42) ขณะที่อุณหภูมิและความเร็วลมมีความสัมพันธ์กับค่า PM2.5 ในระดับค่อนข้างต่ำ (ประมาณ 0.10 และ 0.03 ตามลำดับ)

ผลการวิเคราะห์ในขั้นตอนนี้ช่วยให้เห็นภาพรวมของข้อมูลและยืนยันว่า ตัวแปรด้านสภาพอากาศบางตัวมีแนวโน้มเกี่ยวข้องกับการเปลี่ยนแปลงของค่าฝุ่น PM2.5 จึงสามารถนำไปใช้เป็นข้อมูลประกอบในการสร้างแบบจำลองพยากรณ์ในขั้นตอนถัดไป

4.2 ผลการสร้างแบบจำลองพยากรณ์

ในการสร้างแบบจำลอง ผู้จัดทำกำหนดตัวแปรอิสระเป็น month, temperature, humidity และ wind_speed และกำหนดตัวแปรเป้าหมายเป็น pm25_daily จากนั้นใช้ PyCaret เพื่อเปรียบเทียบแบบจำลอง Regression หลายประเภท และเลือกโมเดลที่ให้ค่าความคลาดเคลื่อนต่ำที่สุดตามเกณฑ์ RMSE

ผลการทดลองพบว่าโมเดล Gradient Boosting Regressor ให้ผลลัพธ์ดีที่สุดเมื่อพิจารณาจากค่า RMSE (ประมาณ 11.20) และมีค่า MAE ประมาณ 8.03 ซึ่งสะท้อนว่าโมเดลสามารถนำมาใช้พยากรณ์ค่า PM2.5 ได้ในระดับที่เหมาะสมสำหรับการใช้งานเบื้องต้น

ทั้งนี้ความแม่นยำของโมเดลอาจยังได้รับผลกระทบจากปัจจัยอื่นที่ไม่ได้รวมอยู่ในชุดข้อมูล เช่น แหล่งกำเนิดมลพิษเฉพาะพื้นที่หรือสภาพการจราจร

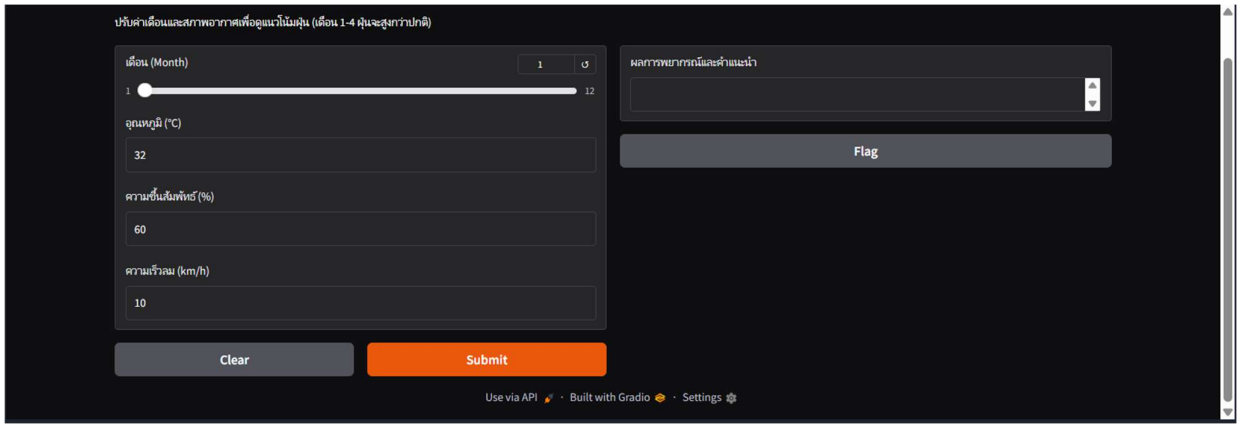

รูปที่ 9 หน้าจอระบบสาธิตการพยากรณ์ PM2.5

บทที่ 5

อภิปรายและสรุปผลการดำเนินงาน

5.1 อภิปรายผลการดำเนินงาน

จากการดำเนินโครงงานตามกระบวนการ CRISP-DM พบว่า การวิเคราะห์ข้อมูลค่า PM2.5 ร่วมกับข้อมูลสภาพอากาศสามารถช่วยให้เข้าใจแนวโน้มและปัจจัยที่เกี่ยวข้องกับการเปลี่ยนแปลงของค่าฝุ่นได้ในระดับหนึ่ง โดยผลการวิเคราะห์ความสัมพันธ์ (Correlation) แสดงให้เห็นว่า ความชื้นสัมพัทธ์มีความสัมพันธ์เชิงลบกับค่า PM2.5 อย่างค่อนข้างชัดเจน ขณะที่อุณหภูมิและความเร็วลมมีความสัมพันธ์ในระดับต่ำ ซึ่งสะท้อนว่าปัจจัยด้านสภาพอากาศมีผลต่อค่าฝุ่น แต่ยังไม่ใช่ปัจจัยหลักทั้งหมด

ในส่วนของการสร้างแบบจำลอง พบว่าโมเดล Gradient Boosting Regressor สามารถให้ผลลัพธ์ที่ดีที่สุดเมื่อเทียบกับโมเดลอื่น ๆ โดยมีค่าความคลาดเคลื่อน (RMSE และ MAE) อยู่ในระดับที่ยอมรับได้สำหรับการใช้งานเบื้องต้น แสดงให้เห็นว่าโมเดลสามารถเรียนรู้รูปแบบของข้อมูลและนำไปใช้พยากรณ์ค่า PM2.5 ได้ในระดับหนึ่ง

ผลการดำเนินงานยังมีข้อจำกัดบางประการ เช่น การใช้ตัวแปรเพียงบางส่วนของปัจจัยที่เกี่ยวข้อง โดยยังไม่ได้รวมปัจจัยสำคัญอื่น ๆ เช่น ปริมาณการจราจร แหล่งกำเนิดมลพิษในพื้นที่ หรือเหตุการณ์พิเศษ ซึ่งอาจส่งผลต่อความแม่นยำของโมเดล นอกจากนี้ การใช้ข้อมูลเฉลี่ยรายวันอาจทำให้สูญเสียรายละเอียดในระดับรายชั่วโมงที่อาจมีผลต่อการพยากรณ์

5.2 สรุปผลการดำเนินงาน

โมเดลประสบความสำเร็จตามวัตถุประสงค์ที่ตั้งไว้ และสามารถนำไปต่อยอดในการพัฒนาโมเดลที่มีความแม่นยำมากขึ้น รวมถึงประยุกต์ใช้กับงานวิเคราะห์ข้อมูลด้านสิ่งแวดล้อมในอนาคตได้